

Xây dựng Data Lakehouse phục vụ phân tích và giám sát thị trường chứng khoán HOSE

[HỌ VÀ TÊN SINH VIÊN], [HỌ VÀ TÊN MENTOR]¹

¹[ĐƠN VỊ MENTOR HƯỚNG DẪN]

Email mentor: [EMAIL MENTOR HƯỚNG DẪN]

Abstract—Để tài xây dựng một Data Lakehouse cho cổ phiếu niêm yết trên HOSE, bao phủ quá trình thu thập, lưu trữ, làm sạch, kiểm soát chất lượng, mô hình hóa và cung cấp dữ liệu cho dashboard. Dữ liệu batch gồm OHLCV, danh mục doanh nghiệp, VNINDEX, VN30 và tin tức từ ba báo; dữ liệu gần thời gian thực gồm trade tick DNSE và sự kiện cảnh báo. Ba lớp Bronze-Silver-Gold được lưu dạng Parquet trên MinIO, trong khi ClickHouse đóng vai trò serving; Airflow điều phối pipeline ngày, Kafka Engine tiếp nhận tick, PostgreSQL lưu cấu hình cảnh báo, dbt kiểm thử mô hình phân tích và FastAPI/React cung cấp bảy màn hình nghiệp vụ. Tại thời điểm đánh giá 28/06/2026, hệ thống quản lý 403 mã HOSE, 12.963 dòng giá ngày, 66 dòng chỉ số và 640 dòng tổng hợp cảm xúc; đối soát Bronze-Silver-Gold không phát hiện mất hoặc trùng khóa. Kết quả kiểm chứng gồm 164/164 kiểm thử Python, 26/26 kiểm thử dbt, lint và frontend build đều thành công. Báo cáo đồng thời chỉ ra các giới hạn còn lại: luồng NLP chưa được điều phối hoàn chỉnh, realtime mới có dữ liệu ba mã, producer DNSE chưa là service thường trực và bước migration hàng ngày đang làm mất hiệu lực của chiến lược Gold incremental.

Index Terms—Data Lakehouse, HOSE, Airflow, MinIO, ClickHouse, Kafka, dbt, Parquet, data quality, VWAP.

I. GIỚI THIỆU CHUNG

Dữ liệu chứng khoán có nhiều dạng và tốc độ thay đổi khác nhau: giá ngày là chuỗi thời gian có cấu trúc; hồ sơ doanh nghiệp thay đổi chậm; tin tức là văn bản bán cấu trúc; còn trade tick phát sinh liên tục trong phiên. Cách tải tệp thủ công khó truy vết nguồn, dễ tạo bản ghi trùng, không bảo đảm dữ liệu dashboard được cập nhật và thiếu cơ chế phát hiện sai lệch giữa các bước. Vì vậy, đề tài đặt mục tiêu xây dựng một nền tảng dữ liệu thống nhất, có thể tái chạy, kiểm tra được và tách lớp lưu trữ lâu dài khỏi lớp truy vấn nhanh.

Phạm vi nghiệp vụ được giới hạn xuyên suốt ở 403 cổ phiếu HOSE và hai chỉ số VNINDEX, VN30. Mục tiêu cụ thể gồm: (i) thu thập dữ liệu đa nguồn theo batch và streaming; (ii) tổ chức Bronze-Silver-Gold bằng Parquet; (iii) kiểm soát

schema, chất lượng, độ tươi và số dòng; (iv) mô hình hóa Gold phục vụ phân tích; (v) cung cấp API, dashboard, VWAP và cảnh báo kỹ thuật; (vi) đóng gói môi trường để có thể tái lập.

Sinh viên trực tiếp khảo sát nguồn, thiết kế partition, xây dựng các module ingestion/transform/quality/load bằng Python và Polars, thiết kế DDL ClickHouse/PostgreSQL, DAG Airflow, mô hình dbt, Kafka Engine, Alert Engine, FastAPI và frontend React. Đóng góp chính là chuyển hệ thống từ tập lệnh thu thập rời rạc thành một pipeline có dependency, quality gate, đối soát ba lớp và lớp serving thống nhất; đồng thời làm sạch phạm vi HOSE và bảo vệ các bảng realtime khỏi thao tác batch không phù hợp.

II. NỘI DUNG VÀ PHƯƠNG PHÁP

A. Nguồn dữ liệu và cách xử lý

Bảng I trình bày nguồn thật được xác nhận từ code. Vũ trụ mã lấy bằng Listing(source="kbs") và lọc exchange=HOSE, type=STOCK. Giá ngày từng mã và chỉ số lấy qua Quote(source="VCI").history(..., interval="1D"). DAG lấy cửa sổ 30 ngày gần nhất; OHLCV được gọi tuần tự, nghỉ 5 giây giữa các mã và bỏ qua file đã tồn tại trong ngày ingest để giảm rate limit.

Crawler tin tức có parser riêng cho từng website và giới hạn bài tối đa hai ngày tuổi. URL được chuẩn hóa, bỏ tham số tracking và ghi vào SQLite registry với trạng thái discovered/success/skipped/failed, số lần thử và thời điểm retry. Silver yêu cầu URL, tiêu đề, nguồn, ngày đăng và nội dung tối thiểu 50 ký tự. Entity linking tạo từ điển alias từ mã và tên doanh nghiệp, dùng biên regex cho ticker ngắn, sau đó khử trùng khóa article_id, ticker. Gold hiện dùng từ điển tích cực/tiêu cực để tạo ba nhãn; service NLP và script inference đã tồn tại nhưng chưa sinh tập news_sentiment_detail, do đó chưa được coi là luồng hoàn chỉnh.

TABLE I
Nguồn dữ liệu, xử lý và đầu ra

Tập dữ liệu	Nguồn	Bronze và Silver	Gold/biến đổi chính	Nhịp hiện tại
OHLCV HOSE	vnstock: KBS list- ing, VCI quote	Raw theo mã/ngày ingest; ép kiểu, loại giá không hợp lệ, khử trùng ticker, date	Giá, khối lượng, giá trị, vốn hóa, SMA/EMA, MACD, RSI14, Bollinger, cờ tín hiệu	18:00 thứ Hai-Sáu
Hồ sơ doanh nghiệp	KBS listing/profile	Chuẩn hóa mã, tên, sàn, ngành, số cổ phiếu; lọc HOSE và duy nhất theo mã	dim_stock, dim_sector; cung cấp shares outstanding	Listing theo DAG ngày; profile thay đổi chậm
Chỉ số	VCI: VNINDEX, VN30	Raw theo chỉ số/ngày ingest; chỉ giữ hai mã cấu hình, kiểm tra OHLC	Điểm số, biến động, breadth tăng/giảm, SMA20, RSI14	18:00 thứ Hai-Sáu
Tin tức	VnExpress, Vietstock, CafeF	Chuẩn hóa URL/text/ngày; registry SQLite chỉ tải URL mới; loại bài ngắn/trùng	Regex liên kết bài-mã; sentiment từ điểm ba nhân và tổng hợp mã-ngày	Có loop 5 phút nhưng chưa được quản lý như service
Trade tick	DNSE WebSocket	Chuẩn hóa ticker, trade_ts, price, volume; có thể ghi Bronze và publish Kafka	OHLC phút, VWAP phút, VWAP phiên, volume/value lũy kế	Script realtime; chưa chạy thường trực
Cảnh báo	Rule trong Post- greSQL	Đọc giá/RSI/Bollinger/VWAP mới nhất; mở rộng rule ALL cho toàn HOSE	Sự kiện PRICE, RSI, BB, VWAP và trạng thái giao nhận	Engine kiểm tra mỗi 60 giây

B. Kiến trúc ba lớp và phân vùng

Bronze giữ dữ liệu gần nguyên nguồn để truy vết; Silver chuẩn hóa schema và business key; Gold tổ chức theo star schema và chỉ số phục vụ dashboard. Cả ba lớp được xuất Parquet lên MinIO [2], [3]; ClickHouse chỉ đảm nhiệm serving phân tích. Cách phân vùng được chọn theo grain truy vấn thay vì dùng một quy tắc chung:

- Bronze OHLCV: ticker/year/month/day; index: index_code/year/month/day; profile, news và DNSE: theo dataset/source và ngày ingest.
- Silver OHLCV: ticker/year/month; profile, index và news: year/month.
- Gold MinIO: dimension theo snapshot_date; fact ngày theo year/month; VWAP theo trading_date. Trong ClickHouse, fact giá/index/news/alert partition theo tháng, VWAP theo ngày; sort key bắt đầu bằng mã và thời gian.

Gold gồm bốn dimension (ngày, cổ phiếu, ngành, chỉ số) và năm fact nghiệp vụ chính: giá ngày, chỉ số, cảm xúc tin tức ngày, VWAP phút và sự kiện cảnh báo. Các chỉ báo rolling được tính trên toàn bộ lịch sử mỗi mã bằng Polars để tránh sai tại biên cửa sổ, sau đó loader dự kiến chỉ ghi lại các tháng bị ảnh hưởng theo watermark lùi 35 ngày. dbt tạo staging table và mart fact_daily_price_indicators dạng incremental delete_insert, đồng thời kiểm tra not-null, unique, market cap và công thức MACD [7].

C. Điều phối, chất lượng và tính tái chạy

DAG stock_lakehouse_daily chạy lúc 18:00 từ thứ Hai đến thứ Sáu, timezone Asia/Ho_Chí_Minh, retry một lần và chỉ cho phép một run hoạt động. Phiên bản hiện tại định nghĩa 19 task: khởi tạo MinIO; bốn nhánh Bronze; bốn nhánh Silver;

quality gate; migration/load/reconciliation Gold; export Gold; init/check alert; dbt run/test; export snapshot frontend. Dependency buộc tất cả Silver thành công trước quality, và chỉ xuất/alert/dbt sau khi reconciliation pass. Airflow lưu lịch sử điều phối và cung cấp REST API cho màn hình giám sát [4].

Quality gate kiểm tra cột bắt buộc, null, miền giá trị, quan hệ OHLC, mã sàn/chỉ số hợp lệ và uniqueness. Bước reconciliation so số khóa phân biệt Bronze-Silver, yêu cầu Silver-Gold bằng tuyệt đối, kiểm tra duplicate business key trên ClickHouse và SLA hai ngày làm việc. Báo cáo JSON được API đọc để hiển thị lỗi. Với bảng batch, thao tác nạp lại theo partition làm run có tính idempotent; với VWAP, consumer tái tính dữ liệu trong ngày từ raw ticks rồi drop/nạp lại đúng partition ngày.

D. Streaming, alert và lớp phục vụ

Trade tick được publish vào topic dnse-trades-raw. ClickHouse Kafka Engine cùng Materialized View chỉ làm nhiệm vụ đưa message vào realtime_trade_ticks_raw; tiến trình Python mỗi 15 giây tổng hợp thành fact_realtime_vwap. Thiết kế này tái sử dụng một hàm tính VWAP đã được kiểm thử và giữ raw ticks để tái xử lý. Tuy nhiên Docker Compose hiện chỉ quản lý consumer, chưa quản lý producer DNSE.

Rule cảnh báo lưu trong PostgreSQL vì cần cập nhật giao dịch; lịch sử sự kiện lưu trong ClickHouse vì chủ yếu append và phân tích theo thời gian. Engine hỗ trợ giá vượt/dưới ngưỡng, RSI, Bollinger và độ lệch VWAP. Cooldown truy vấn cả sự kiện gửi thất bại để tránh lặp khi kênh chưa cấu hình; trigger trong cooldown không ghi thêm dòng. Trạng thái giao nhận phân biệt

TABLE II
Kết quả dữ liệu và kiểm chứng

Đối tượng	Số lượng	Phạm vi/ghi chú
dim_stock	403	403 mã, chỉ HOSE
dim_sector	30	Nhóm ngành
dim_date	4.018	2020-2030
dim_index	2	VNINDEX, VN30
fact_daily_price	12.963	403 mã; 12/12/2024- 26/06/2026
fact_market_index	66	13/05-26/06/2026
fact_news_sentiment_	640	158 mã; 12- 26/06/2026
daily		
fact_realtime_vwap	15	3 mã; 5 phút dữ liệu
Raw realtime	60	FPT, HPG, VCB
Python test	164/164	Pass; 2 cảnh báo phiên bản thư viện
dbt	2 model; 26/26	Run và data test pass
Reconciliation	8/8	Count, duplicate, freshness pass

sent, send_failed, channel_not_configured và unknown_channel.

FastAPI cung cấp tám nhóm endpoint: health, danh sách/nền cổ phiếu, tổng quan thị trường, VWAP, tín hiệu kỹ thuật, sentiment, alert và pipeline. React/Vite cung cấp bảy màn hình tương ứng: Tổng quan, Chi tiết cổ phiếu, Tín hiệu, VWAP, Tin tức, Cảnh báo và Giám sát pipeline. Super-set/Grafana được dùng bổ sung cho phân tích và quan sát vận hành. API pipeline lấy trạng thái task thật từ Airflow REST, chỉ fallback sang ClickHouse khi Airflow không phản hồi; chỉ số “độ trễ VWAP” được ghi rõ là proxy khoảng cách giữa các phút đã hạ cảnh, chưa phải consumer lag thật.

III. KẾT QUẢ THỰC HIỆN

Số liệu ở Bảng II được truy vấn trực tiếp ngày 28/06/2026. Phạm vi HOSE đã nhất quán ở Silver và Gold; VNINDEX/VN30 không còn lẫn HNXINDEX/UPCOMINDEX. MinIO có 2.945 object Bronze, 406 object Silver và 31 object Gold. Các endpoint chính đều trả HTTP 200.

Airflow run gần nhất đã thành công từ Bronze đến export frontend, gồm task reconciliation chạy 17 giây. Hai task dbt mới đã có trong DAG và được kiểm chứng độc lập (hai model hoàn thành trong khoảng hai giây, 26 test pass), nhưng chưa có một DAG run mới chứa chính hai task này. Frontend production build thành công với 2.285 module; lint ruff không có lỗi. Alert Engine hoạt động và không còn ghi một dòng mỗi chu kỳ cooldown; tại 10:34 UTC có 476 sự kiện trên 92 mã, toàn bộ chưa gửi thành công vì kênh Telegram/SMTP chưa được cấu hình hoàn chỉnh. Mã nguồn và bộ cài gồm src/, scripts/, dags/, sql/, dbt/, frontend/, tests/, file khóa uv và Docker Compose 12 service.

IV. ĐÁNH GIÁ HIỆU QUẢ

A. Điểm mạnh và giá trị đạt được

Thứ nhất, hệ thống có đường dữ liệu end-to-end thay cho xử lý thủ công: nguồn được cấu hình, Bronze giữ bằng chứng, Silver có schema thống nhất, Gold có grain rõ và dashboard không đọc trực tiếp file raw. Thứ hai, phạm vi HOSE được thực thi ở listing, transform, quality và API, giảm rủi ro trộn sần. Thứ ba, partition bám theo truy vấn giúp tránh quá nhiều thư mục ticker ở Gold nhưng vẫn đọc lịch sử từng mã hiệu quả ở Silver. Thứ tư, quality gate và reconciliation đã chứng minh 12.963 khóa OHLCV và 66 khóa index đi qua ba lớp không mất/trùng. Thứ năm, việc tách PostgreSQL rule khỏi ClickHouse event, Kafka raw khỏi VWAP aggregate, MinIO storage khỏi ClickHouse serving làm rõ ownership và khả năng tái xử lý. Bộ test, dbt test, lint, build và API check tạo nhiều lớp bằng chứng thay vì chỉ dựa vào giao diện.

B. Điểm yếu và nguyên nhân

P0 - migration làm vô hiệu incremental. DAG vẫn chạy migrate_gold_schema.py để drop các dimension và batch fact trước load_gold.py. Vì fact_daily_price và fact_market_index bị tạo lại, watermark luôn rỗng; loader dù có logic lookback/affected-month vẫn phải nạp toàn bộ. Cách sửa đúng là migration chỉ CREATEIFNOTEXISTS/ALTERTABLE và tách migration schema khỏi lịch hàng ngày. Đây là hạn chế lớn nhất của batch hiện tại.

P0 - news/NLP chưa khép kín. Bronze có 675 dòng, Silver 634 dòng và 1.096 liên kết bài-mã, nhưng chưa có file news_sentiment_detail. Loop 5 phút không chạy như Docker/Airflow service; DAG ngày không gọi entity linking và inference. Health NLP cũng báo model_loaded=true nhưng version lại là fallback-rule-based, cần sửa contract và đánh giá trên tập tin tài chính gắn nhãn.

P1 - realtime chưa vận hành liên tục. Dữ liệu VWAP mới phủ FPT, HPG, VCB; script producer DNSE không có process thường trực và không nằm trong Compose. API hiển thị universe 403 nhưng active realtime chỉ ba mã. Cần thêm producer service, subscription batching, reconnect/backoff, metric offset và thử tải trong giờ giao dịch.

P1 - alert mới hoàn thiện logic, chưa hoàn thiện delivery. Telegram thiếu secret; SMTP mới là placeholder. Điều kiện kéo dài sẽ tạo lại một event sau mỗi cửa sổ cooldown, đúng theo thiết kế hiện tại nhưng có thể vẫn nhiều cho rule ALL. Nên bổ sung trạng thái mở/đóng sự kiện, first_seen, last_seen và suppressed_count.

P2 - observability và quản trị còn cơ bản.

Reconciliation mới so count và duplicate, chưa anti-join tập business key; SLA chỉ dùng thứ Hai-Sáu, chưa có lịch nghỉ HOSE. "VWAP lag" chưa phải Kafka offset lag. Frontend vẫn mang file fallback lớn khoảng 1,4 MB. Secret đang ở biến môi trường/default local; chưa có secret manager, backup/restore, lineage, catalog, benchmark throughput và cảnh báo SLA chủ động.

So với cách chạy thử công, giải pháp tăng tính lặp lại, khả năng phát hiện lỗi và thời gian truy cập dữ liệu; tuy nhiên chưa đủ bằng chứng để khẳng định production-ready do thiếu benchmark, HA, security hardening và vận hành realtime/NLP đầy đủ. Đánh giá hiện tại: kiến trúc và batch/quality đạt mức tốt cho đồ án Data Engineer; realtime, NLP và vận hành production vẫn là các hạng mục phát triển tiếp.

V. KẾT LUẬN

Đề tài đã hiện thực một Data Lakehouse có thể chạy và kiểm chứng cho 403 mã HOSE: thu thập đa nguồn, Parquet ba lớp trên MinIO, Gold ClickHouse, Airflow, dbt, Kafka Engine, Alert Engine, FastAPI và dashboard. Điểm nổi bật không chỉ nằm ở số công nghệ sử dụng mà ở các quyết định data engineering: business key và partition theo grain, quality gate trước serving, reconciliation ba lớp, tách ownership batch/streaming và minh bạch fallback trên API. Kết quả 164 test Python, 26 test dbt, frontend build và dữ liệu đối soát khớp cho thấy lỗi batch đã ổn định.

Thứ tự phát triển tiếp theo là: (1) bỏ thao tác drop bảng khỏi DAG để incremental thực sự có hiệu lực; (2) đóng gói producer DNSE và pipeline news 5 phút thành service/DAG riêng; (3) tích hợp inference ba nhãn, đánh giá bằng dữ liệu tài chính gán nhãn và nạp Gold detail; (4) hoàn thiện Telegram/SMTP và mô hình trạng thái alert; (5) đo Kafka lag thật, thêm key-set reconciliation, lịch giao dịch HOSE, benchmark và quản trị secret. Kiến trúc hiện tại đủ mô-đun để mở rộng nguồn hoặc sàn sau khi các điểm trên được hoàn thiện.

TÀI LIỆU THAM KHẢO

- [1] M. Armbrust *et al.*, "Lakehouse: A New Generation of Open Platforms that Unify Data Warehousing and Advanced Analytics," in *CIDR*, 2021.
- [2] Apache Software Foundation, "Apache Parquet Documentation," [Online]. Available: <https://parquet.apache.org/docs/>. Accessed: Jun. 28, 2026.
- [3] MinIO, "MinIO Object Store Documentation," [Online]. Available: <https://min.io/docs/>. Accessed: Jun. 28, 2026.
- [4] Apache Software Foundation, "Apache Airflow Documentation," [Online]. Available: <https://airflow.apache.org/docs/>. Accessed: Jun. 28, 2026.
- [5] ClickHouse, Inc., "ClickHouse Documentation," [Online]. Available: <https://clickhouse.com/docs>. Accessed: Jun. 28, 2026.
- [6] J. Kreps, N. Narkhede, and J. Rao, "Kafka: A Distributed Messaging System for Log Processing," in *NetDB*, 2011.
- [7] dbt Labs, "dbt Developer Hub," [Online]. Available: <https://docs.getdbt.com/>. Accessed: Jun. 28, 2026.